Mahoraga 6.1 y 7C.3: arquitectura cuantitativa con control adaptativo, detección de régimen y aprendizaje automático para una estrategia sistemática sobre tecnología

Marzo de 2026

Resumen

Este documento presenta la lógica, el origen, el pipeline y los resultados de la familia de modelos Mahoraga, con énfasis en Mahoraga 6.1 como base cuantitativa endurecida y en Mahoraga 7C.3 como capa superior de detección de fragilidad y recuperación mediante aprendizaje automático. El problema central no es predecir precios de forma mágica, sino construir una estrategia sistemática capaz de participar en el crecimiento del sector tecnológico sin quedar excesivamente expuesta cuando el entorno cambia de régimen.

El sistema parte de un universo canónico de grandes acciones tecnológicas, utiliza una validación walk-forward fuera de muestra, incorpora controles de riesgo adaptativos y, en su versión 7C.3, añade una capa Hawkes inspirada en procesos autoexcitados y dos modelos Random Forest para detectar fragilidad del baseline y oportunidades de recuperación. En Mahoraga 6.1, el desempeño fuera de muestra continuo supera a QQQ en Sharpe y drawdown, con retorno comparable y menor exposición media. En Mahoraga 7C.3, la mejora es incremental pero consistente en el promedio por fold y más valiosa en entornos de estrés que en normalidad.

La aportación principal del proyecto no es vender una ilusión de predicción perfecta, sino mostrar una arquitectura disciplinada, explicable y modular que combina ingeniería cuantitativa, estadística adaptativa y aprendizaje automático acotado para mejorar la robustez del sistema base.

1. Introducción

Los mercados financieros premian la disciplina, pero castigan con rapidez la sobreconfianza. Esa tensión es todavía más evidente en el sector tecnológico: es un segmento que concentra

innovación, crecimiento y liderazgo de mercado, pero también episodios de sobrevaloración, compresión de múltiplos, alta correlación interna y caídas simultáneas cuando el régimen macroeconómico cambia. Por ello, una estrategia centrada en tecnología no puede limitarse a "comprar y esperar" ni tampoco depender de predicciones puntuales sobre el precio del día siguiente. Necesita una arquitectura que sepa participar, reducir riesgo y reactivarse de manera razonable.

Bajo esa necesidad surge Mahoraga. Su evolución no parte de la búsqueda de un truco, sino de una secuencia lógica de investigación. Primero, se construye una base cuantitativa robusta y auditada. Después, se añade una capa de detección de régimen capaz de identificar estrés y recuperación agrupados en el tiempo. Finalmente, se incorpora una capa de aprendizaje automático que no reemplaza a la estrategia base, sino que vigila cuándo esa base se vuelve frágil y cuándo conviene permitir una recuperación más agresiva.

En otras palabras, Mahoraga no debe entenderse como un predictor de mercado, sino como una arquitectura de decisión por capas. Esa distinción es importante, porque permite explicar con honestidad qué hace el sistema, cómo lo hace, por qué lo hace y qué resultados ofrece realmente.

2. Planteamiento del problema

2.1. Qué problema se busca resolver

El problema central del proyecto es el siguiente: **cómo construir una estrategia sistemática sobre acciones tecnológicas de gran tamaño que mantenga una trayectoria eficiente entre retorno y riesgo, y que además se adapte cuando el mercado entra en episodios de estrés o recuperación**.

Este problema tiene varias dimensiones:

a) el sector tecnológico puede ofrecer retornos muy altos, pero también drawdowns severos;

b) la diversificación aparente puede romperse cuando los activos comienzan a moverse juntos;

c) una estrategia que funciona bien en un régimen puede deteriorarse en otro;

d) optimizar una sola vez sobre toda la historia puede producir una ilusión de robustez.

2.2. Por qué es un problema importante

Resolver este problema importa porque los benchmarks más usados no necesariamente resuelven el dilema completo. QQQ, por ejemplo, es una referencia fuerte para exposición al crecimiento tecnológico, pero sufre drawdowns relevantes cuando el entorno se deteriora.

SPY, por su parte, funciona como referencia amplia del mercado estadounidense, pero no representa la dinámica específica de concentración, innovación y sensibilidad al régimen que caracteriza al bloque tecnológico. Por ello, superar a QQQ en eficiencia riesgo–retorno es una señal relevante, porque implica no solo competir contra un benchmark conocido, sino hacerlo en el terreno más exigente para una estrategia temática de tecnología.

2.3. Objetivo

Desarrollar una arquitectura cuantitativa explicable para la gestión de portafolios tecnológicos que combine selección sistemática de activos, control adaptativo del riesgo, detección de régimen y aprendizaje automático supervisado, con la finalidad de mejorar la eficiencia riesgo-retorno frente a referentes como QQQ y aportar una solución más robusta y comprensible en entornos normales y de estrés de mercado.

3. Origen y evolución del proyecto

La lógica de evolución del proyecto puede resumirse en tres etapas.

3.1. Etapa 1: Mahoraga 6.1 como base cuantitativa endurecida

Mahoraga 6.1 es la versión que consolida la base del sistema. Su función no es ser la capa más "inteligente", sino la más confiable. En esta etapa se corrigen problemas de auditoría y reporte, se fortalece la pureza del walk-forward, se añade una defensa por correlación y se clarifica la trazabilidad del experimento.

3.2. Etapa 2: Mahoraga 7 como capa de régimen

Una vez identificadas las zonas de debilidad de 6.1, la siguiente pregunta natural es si el sistema puede reaccionar más rápido cuando el estrés se agrupa o cuando aparece una recuperación sostenida. Ahí surge Mahoraga 7, con una capa Hawkes inspirada en procesos autoexcitados. La idea no es predecir precios, sino detectar secuencias de estrés y secuencias de recuperación.

3.3. Etapa 3: Mahoraga 7C.3 como supervisión dual con machine learning

Finalmente, Mahoraga 7C.3 incorpora una capa dual de aprendizaje automático. Esta capa no compra ni vende por sí sola. Tampoco reemplaza a Mahoraga 6.1. Su papel es más específico: estimar cuándo el baseline parece frágil y cuándo existe una recuperación con suficiente evidencia como para aliviar el modo defensivo.

La evolución completa del proyecto es, por tanto, coherente:

base robusta → detección estructural de régimen → intervención acotada guiada por ML.

4. Datos y universo de estudio

4.1. Qué datos se utilizan

El sistema trabaja con precios y volúmenes históricos descargados mediante `yfinance`. Esto debe declararse con honestidad: no se trata de una base institucional tipo CRSP/Compustat. Por ello, los resultados deben entenderse como una investigación seria con proxy de simulación, no como evidencia definitiva de alfa generalizable.

4.2. Construcción del universo

El universo base es un conjunto de empresas tecnológicas de gran capitalización, entre ellas AAPL, MSFT, NVDA, GOOGL, AMZN, META, AVGO, ASML, TSM, ADBE, NFLX y AMD. Sin embargo, la estrategia no opera como un conjunto estático inmóvil. Utiliza un motor canónico con reconstitución trimestral que rankea candidatos mediante una variable llamada *LiqSizeProxy*, definida como el promedio de precio × volumen en 30 días.

Este criterio no equivale a market cap flotante real ni a una clasificación sectorial institucional. En consecuencia, el propio proyecto reconoce que el sesgo de supervivencia no puede eliminarse por completo con los datos disponibles.

4.3. ¿Por qué esta decisión es razonable?

La razón para usar este enfoque es práctica y metodológica. Si no se dispone de una base point-in-time institucional con información exacta de capitalización flotante y clasificación sectorial histórica, es preferible usar un criterio explícito, reproducible y coherente de liquidez-tamaño antes que fingir una pureza de universo que en realidad no existe. Además, las reglas de entrada, retención, buffer y seasoning ayudan a que el universo no cambie de forma caótica.

4.4. Configuración principal del universo

Cuadro 1: Parámetros principales del universo canónico

Parámetro	Valor
Modo de universo	Motor canónico
Frecuencia de reconstitución	Trimestral (QS)
Tamaño objetivo	10 activos
Entrada automática	Hasta rank 8
Retención	Hasta rank 10
Buffer	Hasta rank 13
Seasoning mínimo	63 días
ADDV mínimo aproximado	50 millones USD
Fuente de datos	yfinance
Sesgo de supervivencia	Presente

5. Pipeline completo del sistema

El pipeline del proyecto puede explicarse con una secuencia clara:

1. Se descargan precios, volúmenes y benchmarks.
2. Se limpia el universo y se aplica una capa de calidad de datos.
3. Se construye un calendario canónico de universo point-in-time aproximado.
4. Se divide la historia en folds walk-forward.
5. En cada fold se recalibran umbrales y pesos usando solo el tramo de entrenamiento.
6. Se ejecuta un sweep de parámetros en validación.
7. Se congela la mejor configuración del fold.
8. Se prueba fuera de muestra.
9. En 7 y 7C.3, sobre ese baseline congelado se añade una capa de régimen y, después, una capa dual de ML.
10. Finalmente, se agregan métricas, auditorías por fold y comparaciones por régimen.

Esta secuencia es importante porque evita mezclar entrenamiento y prueba, permite explicar cada decisión y deja un rastro verificable de cómo se llegó al resultado final.

6. Mahoraga 6.1: el núcleo cuantitativo endurecido

6.1. Qué es Mahoraga 6.1

Mahoraga 6.1 es la base ejecutiva y de riesgo del sistema. No es un predictor de precios y no depende todavía del aprendizaje automático como componente central. Su objetivo es combinar una selección sistemática de activos con mecanismos de control adaptativo que permitan participar en el crecimiento tecnológico sin quedar completamente expuesto cuando el régimen se deteriora.

6.2. Cómo puntúa activos

Mahoraga 6.1 construye una puntuación compuesta a partir de tres bloques:

a) **Tendencia**: votación de cruces de medias exponenciales.

b) **Momentum**: rendimiento acumulado en distintas ventanas.

c) **Fuerza relativa**: comparación del activo contra QQQ en varias ventanas.

La puntuación final se calcula como una combinación ponderada de esos tres componentes. Es decir, el sistema no selecciona activos por un solo criterio, sino por una lectura compuesta del comportamiento del precio.

6.3. Por qué se usan esos tres componentes

Se usan porque cubren preguntas distintas:

- la tendencia pregunta si el activo conserva dirección;
- el momentum pregunta si el avance reciente sigue siendo fuerte;
- la fuerza relativa pregunta si el activo está ganando frente al benchmark tecnológico.

Usarlos juntos ayuda a que la estrategia no dependa de una sola narrativa del mercado.

6.4. Cómo se ajustan sus pesos

Los pesos de tendencia, momentum y fuerza relativa no se asignan de manera arbitraria. Se estiman con un esquema de *Information Coefficient* usando correlación de Spearman entre la señal actual y retornos futuros a horizontes de 1, 5 y 21 días. Después, esos pesos se suavizan con una mezcla entre el resultado empírico y una base uniforme, y se acotan para evitar concentraciones extremas.

Esto es importante porque introduce una lógica adaptativa: si una familia de señales ha sido más útil en la ventana de entrenamiento, recibe más peso, pero sin permitir que domine por completo.

6.5. Cómo asigna pesos al portafolio

Una vez seleccionados los activos, la asignación interna del portafolio utiliza *Hierarchical Risk Parity* (HRP). Si la estructura de datos no permite construir la jerarquía con estabilidad, el sistema cae de manera formal a un esquema de volatilidad inversa.

6.6. Por qué HRP

Se usa HRP porque, frente a una simple ponderación igual o a una optimización clásica muy sensible al error, ofrece una forma más robusta de repartir riesgo entre activos correlacionados. En un universo tecnológico, donde muchas empresas pueden moverse juntas en episodios de tensión, este punto es especialmente importante.

7. Estadística adaptativa en Mahoraga 6.1

7.1. Qué se entiende aquí por estadística adaptativa

En este proyecto, **estadística adaptativa** significa que los umbrales, pesos y escalas no se fijan una vez para siempre, sino que se recalibran usando la información disponible en cada ventana de entrenamiento. No se trata de dejar que el modelo "improvise", sino de permitirle ajustarse de manera disciplinada al contexto histórico reciente del fold.

7.2. Cómo se aplica

Mahoraga 6.1 aplica estadística adaptativa de varias maneras:

a) **Calibración del gate de crisis**: los umbrales de drawdown y de volatilidad-z se calibran sobre el tramo de entrenamiento, no sobre toda la historia.

b) **Pesos de señales por IC**: la importancia de tendencia, momentum y fuerza relativa se estima empíricamente mediante Spearman en diferentes horizontes.

c) **Normalización dinámica**: varias señales se llevan a z-scores y percentiles en ventanas rodantes, para que el sistema compare condiciones actuales con su historia reciente.

d) **Corrección por múltiples pruebas**: el proceso de selección reporta p-values y q-values, lo que evita vender una combinación como sólida solo porque tuvo suerte en una búsqueda grande.

e) **Walk-forward**: la estrategia se obliga a recalibrarse por bloques, que es la forma más completa de estadística adaptativa dentro de un diseño honesto.

7.3. Por qué es valiosa

Es valiosa porque los mercados no son estáticos. Un umbral que funciona en una década puede ser demasiado rígido o demasiado laxo en otra. Si la estrategia no se adapta de forma controlada, corre dos riesgos opuestos: reaccionar tarde o reaccionar de más.

8. Control de riesgo adaptativo en Mahoraga 6.1

8.1. Gate de crisis

Qué es

Es un mecanismo que reduce exposición cuando QQQ entra en una combinación suficientemente fuerte de drawdown y volatilidad elevada.

Cómo funciona

Se calcula el drawdown de QQQ y un z-score de volatilidad. Si las condiciones superan umbrales calibrados en el entrenamiento, se activa un estado de crisis. Ese estado no cambia de inmediato con cualquier ruido; utiliza persistencia mínima para entrar y salir.

Por qué se usa

Porque muchas estrategias fallan no en la selección de activos, sino en la velocidad con que aceptan que el régimen cambió. El gate de crisis intenta resolver esa lentitud.

8.2. Escala de turbulencia

Qué es

Es una escala continua entre un mínimo y 1 que resume qué tan hostil parece el entorno del mercado.

Cómo funciona

La turbulencia se construye con tres ingredientes:

I) volatilidad de QQQ,

II) correlación promedio entre los activos,

iii) una medida agregada de iliquidez.

Esos componentes se convierten en z-scores, se suavizan con media exponencial y después se transforman mediante una función logística a una escala de exposición.

Por qué se usa

Porque el riesgo sistémico no siempre aparece solo como caída del benchmark. A veces emerge como incremento simultáneo de volatilidad, de co-movimiento y de fricción de mercado. La turbulencia resume justamente esa intuición.

8.3. Correlation Shield

Qué es

Es un "circuit breaker" de exposición basado en la correlación promedio entre los activos del universo.

Cómo funciona

Si la correlación promedio supera un umbral de entrada, se activa un estado de protección. A partir de ahí, la exposición se reduce con una función de escala. Si la correlación sube demasiado, el sistema puede incluso forzar caja total.

Por qué se usa

Porque tener varios activos no equivale a estar diversificado si todos comienzan a moverse igual. Cuando la correlación colapsa la diversificación, el escudo de correlación intenta reconocer que el portafolio se volvió más frágil de lo que parece.

9. Inspiraciones físicas: qué sí puede afirmarse y qué no

9.1. Navier–Stokes: inspiración válida, pero no implementación literal

Es importante ser rigurosos. En los archivos revisados no aparece un solver explícito de Navier–Stokes ni una resolución de ecuaciones diferenciales de fluidos sobre el mercado. Por ello, no sería correcto afirmar que el proyecto "resuelve Navier–Stokes para predecir precios".

Existe una **inspiración hidrodinámica** o de flujo en la manera en que se modela la turbulencia y el contagio de régimen. El mercado se trata como un sistema donde pueden existir compresión, fricción, aceleración, propagación de estrés y pérdida temporal de estabilidad. Esa intuición se traduce en proxies cuantitativos como volatilidad, correlación, iliquidez y clustering de eventos, no en una ecuación de fluidos resuelta de manera física.

Navier–Stokes funciona aquí como metáfora estructural para pensar en el mercado como un flujo complejo; la implementación real se expresa en escalas de turbulencia, estados de crisis y contagio de régimen.

9.2. Mecánica cuántica: inspiración probabilística, no simulación cuántica

En Mahoraga 6.1 no aparece un Hamiltoniano, una ecuación de Schrödinger ni computación cuántica en el sentido formal. Por ello, no debe afirmarse que el sistema ejecuta física cuántica literal.

Sin embargo, sí existe una lectura **cuasi-cuántica** o inspirada en estados probabilísticos: el sistema trabaja con estados latentes, con transición entre regímenes, con incertidumbre estructurada y con decisiones que dependen de probabilidades y no de certezas binarias simplistas. Más adelante, en 7C.3, esta idea se vuelve todavía más clara al trabajar con probabilidades de fragilidad y de recuperación.

La referencia a mecánica cuántica se usa como marco conceptual para pensar el mercado en términos de estados, transición e incertidumbre, no como una implementación literal de física cuántica.

10. Mahoraga 7: capa Hawkes para detectar régimen

10.1. Qué es una capa Hawkes inspirada

Los procesos Hawkes son modelos autoexcitados: cuando ocurre un evento, aumenta temporalmente la probabilidad de que ocurran más eventos relacionados. Llevado al mercado, esto es útil porque el estrés rara vez aparece como un punto aislado; suele llegar en rachas. La recuperación también puede agruparse.

En Mahoraga 7 no se implementa un Hawkes continuo multivariado estimado por máxima verosimilitud. Lo que se implementa es una versión discreta, explicable y más ligera en costo computacional.

10.2. Cómo se aplica

La capa construye eventos de estrés y recuperación y después genera intensidades exponenciales de ambos tipos. Posteriormente compara esas intensidades con el estado de crisis del baseline y calibra primero la parte Hawkes y después la parte de overlay.

10.3. Por qué se usa Hawkes

Se usa porque aporta algo que el baseline por sí solo no tiene con suficiente claridad: memoria de agrupamiento temporal. Cuando el mercado entra en una secuencia de eventos

negativos, no basta con ver el último día; conviene modelar que la probabilidad de persistencia sube. Esa misma lógica, en sentido inverso, ayuda a detectar si una recuperación es aislada o si empieza a consolidarse.

10.4. Por qué su calibración es en dos etapas

El sistema primero calibra la parte Hawkes con un criterio barato de alineación y solo después corre backtests completos para el overlay. Esta decisión es elegante y práctica: permite conservar rigor sin multiplicar de forma absurda el costo de cómputo. No es solo una solución matemática; también es una buena decisión de ingeniería.

11. Mahoraga 7C.3: capa dual de machine learning

11.1. Qué hace exactamente 7C.3

Mahoraga 7C.3 no predice el precio del activo para mañana. Tampoco decide desde cero qué acciones comprar. Lo que hace es más acotado y, justamente por eso, más sólido:

1. estima la probabilidad de que el baseline 6.1 sea frágil;
2. estima la probabilidad de que exista una recuperación útil;
3. con base en esas probabilidades, selecciona una intervención limitada.

Las acciones permitidas son:

`BASELINE / REL_TILT / DEFENSIVE_LIGHT / RECOVERY_OVERRIDE`

En los outputs revisados, las acciones observadas fueron principalmente `BASELINE`, `DEFENSIVE_LIGHT` y `RECOVERY_OVERRIDE`. La ruta `REL_TILT` quedó diseñada en la política, pero no apareció activada en la corrida analizada.

11.2. Por qué Random Forest

Se elige **Random Forest** por varias razones:

a) funciona bien con relaciones no lineales;

b) tolera interacciones complejas entre variables sin requerir una especificación paramétrica rígida;

c) es más estable y explicable que modelos más opacos cuando el tamaño muestral no es enorme;

d) permite extraer importancia de variables, lo que ayuda mucho en un trabajo que necesita ser defendible ante una audiencia técnica y no técnica.

11.3. Cómo se construye el modelo de fragilidad

El modelo de fragilidad usa una tabla semanal de características que combina variables de mercado, variables de régimen Hawkes y variables internas del propio baseline. La etiqueta objetivo no se define solo como "retorno futuro bajo", sino como una utilidad futura que descuenta una penalización por drawdown. Es decir, el sistema considera que un escenario es frágil no solo si gana poco, sino si además puede dañar la trayectoria del capital.

Esta decisión es muy buena metodológicamente, porque alinea el aprendizaje automático con el objetivo financiero real: no solo crecer, sino crecer sin deteriorarse de forma excesiva.

11.4. Cómo se construye el modelo de recuperación

El modelo de recuperación parte del retorno futuro de QQQ, pero no se queda ahí. También exige condiciones estructurales relacionadas con la escala defensiva previa, el balance entre intensidades de recuperación y estrés, y la amplitud del mercado. En consecuencia, no cualquier rebote se considera recuperación válida; se requiere un rebote con contexto.

11.5. Por qué esa separación en dos modelos

Un mismo mercado puede ser poco atractivo para aumentar exposición, pero tampoco lo bastante malo como para activar una defensa fuerte. Del mismo modo, una señal de recuperación puede existir incluso cuando la fragilidad general aún no desaparece por completo. Tener dos modelos permite representar mejor esa asimetría.

12. Variables utilizadas por el machine learning

La capa de ML se alimenta de tres familias de variables:

12.1. Variables de régimen

Incluyen intensidad de estrés, intensidad de recuperación y el *spread* entre ambas.

12.2. Variables de mercado

Incluyen correlación promedio a 21 y 63 días, dispersión transversal, breadth, retornos recientes de QQQ, drawdown de QQQ, volatilidad de QQQ y nivel de VIX.

12.3. Variables internas del baseline

Incluyen exposición, rotación, estado de crisis, estado de correlación, escalas de turbulencia, escalas de crisis, escalas de correlación y la escala total objetivo del baseline.

El modelo no observa solo lo que pasa afuera. También observa cómo está parado el propio sistema frente al mercado.

13. Resultados de Mahoraga 6.1

13.1. Resultado central fuera de muestra

El resultado más defendible de Mahoraga 6.1 es su tramo fuera de muestra continuo, que mostró:

Cuadro 2: Resultado OOS continuo de Mahoraga 6.1 frente a QQQ

Modelo	CAGR (%)	Sharpe	MaxDD (%)
Mahoraga 6.1	20.75	1.029	-23.94
QQQ	20.14	0.918	-35.24

13.2. Interpretación

La lectura correcta no es que 6.1 "arrasa" al benchmark. La lectura correcta es mejor: **Mahoraga 6.1 consigue un retorno ligeramente superior a QQQ, con mejor Sharpe y con una caída máxima considerablemente menor**. En un sistema orientado a tecnología, esa combinación es muy valiosa porque significa que la mejora no está basada únicamente en correr más riesgo.

13.3. Importancia

Superar a QQQ en Sharpe y drawdown importa porque QQQ es una referencia natural para exposición al crecimiento tecnológico. Si una estrategia temática logra una trayectoria más eficiente que QQQ, entonces no solo está capturando parte del crecimiento del sector: está gestionando mejor el costo del viaje.

13.4. Otras comparaciones

El reporte también muestra comparaciones con un equal-weight tecnológico y con una estrategia momentum 12-1 Top-K. Ambas ofrecen más CAGR, pero con drawdowns y volatilidades sustancialmente peores. Eso vuelve a reforzar la idea central: Mahoraga 6.1 no pretende ser la estrategia más agresiva, sino la más equilibrada entre retorno y daño potencial.

14. Resultados de Mahoraga 7C.3

14.1. Resultado más defendible

En 7C.3, la lectura más sólida no debe apoyarse primero en la tabla OOS global, sino en el *selection audit* y en los resultados por fold. La razón es metodológica: en la versión revisada, el agregado OOS global requiere tratarse con cautela, mientras que el promedio por fold y la comparación por régimen sí muestran de forma limpia el efecto de la capa adicional.

Cuadro 3: Selection audit de 7C.3 frente al baseline congelado

Método	MeanSharpe	MeanCAGR (%)	MeanMaxDD (%)	MeanRecoveryHitRate
Baseline 6.1 congelado	0.9694	22.096	-16.516	—
H7C.3	1.0313	23.184	-16.008	0.8870

14.2. Qué significa este resultado

La mejora existe, pero es **incremental**. 7C.3 no transforma un sistema de forma exponencial en uno extraordinario; mejora un baseline que ya era sólido. Esto es, en realidad, una virtud, ya que demuestra que no hay sobreajuste y que trabaja directamente sobre debilidades reportadas sobre la versión 6.1.

14.3. Resultados por fold

Cuadro 4: Resumen por fold de 7C.3

Fold	Sharpe Base	Sharpe H7C.3	Δ Sharpe	CAGR Base (%)	CAGR H7C.3 (%)
1	0.8611	0.9289	+0.0678	12.79	13.05
2	1.1750	1.2303	+0.0553	23.24	24.57
3	0.3594	0.3591	-0.0003	4.53	4.52
4	2.2034	2.2099	+0.0064	66.95	67.14
5	0.2481	0.4284	+0.1803	2.97	6.64

14.4. Cómo debe leerse esta tabla

El mensaje principal es claro. La capa 7C.3 ayuda poco donde el baseline ya estaba funcionando muy bien, y ayuda más donde el baseline mostraba mayor fragilidad. El caso más importante es el fold 5, donde la mejora en Sharpe y CAGR es la más visible. Esto es exactamente lo que uno esperaría de una capa correctiva bien diseñada: no brillar siempre, sino aportar cuando más se necesita.

14.5. Resultados por régimen

Cuadro 5: Comparación por régimen de mercado

Régimen	Sharpe Base	Sharpe H7C.3	Δ Sharpe
NORMAL	2.4285	2.4356	+0.0071
STRESS	-0.6076	-0.5789	+0.0287
PANIC	-1.6286	-1.6145	+0.0140

14.6. Por qué este resultado es importante

Este cuadro explica muy bien la tesis del proyecto. 7C.3 no fue diseñado para "ganar muchísimo más" en mercados normales, sino para mejorar el comportamiento relativo cuando el entorno se deteriora. Por eso, la ganancia de Sharpe es modesta en normalidad y más útil en estrés y pánico. Esa asimetría es exactamente la que le da sentido a la capa de supervisión.

15. Interpretación de las variables más importantes

15.1. Modelo de fragilidad

Las variables con mayor importancia promedio fueron:

1. `base_total_scale`
2. `turb_scale_weekly`
3. `rel_minus_mom`
4. `base_turnover`
5. `base_exposure`
6. `intensity_spread`

La fragilidad del sistema no depende solo del mercado, sino del estado interno del propio baseline. Si el baseline ya viene comprimido, inestable, rotando demasiado o perdiendo claridad relativa, entonces el modelo lo reconoce como más vulnerable.

15.2. Modelo de recuperación

Las variables con mayor importancia promedio fueron:

1. `vix_level`

2. `qqq_drawdown`
3. `stress_intensity`
4. `intensity_spread`
5. `rel_minus_mom`
6. `avg_corr_63`

La lectura aquí es también clara: el sistema aprende que una recuperación interesante no se reduce a una vela verde. Necesita contexto. Observa miedo agregado, daño previo, estrés acumulado, correlación y señales de mejora relativa antes de permitir alivio.

16. Qué hace realmente la política de decisión

La política final de 7C.3 convierte probabilidades en acciones. Su lógica es la siguiente:

a) si no hay evidencia suficiente de fragilidad ni de recuperación, el sistema permanece en `BASELINE`;

b) si la fragilidad supera un umbral y domina el estrés, activa una defensa ligera;

c) si aparece una recuperación con suficiente evidencia combinada, habilita `RECOVERY_OVERRIDE`;

d) si la situación es ambigua o lateral, evita intervenir de forma excesiva.

En la corrida revisada, la frecuencia observada de acciones fue principalmente:

- `BASELINE`: 65.8 %
- `RECOVERY_OVERRIDE`: 26.6 %
- `DEFENSIVE_LIGHT`: 7.6 %

Esto confirma que el sistema no sobreinterviene. La mayor parte del tiempo deja operar al baseline y actúa solo cuando detecta suficiente evidencia para hacerlo.

17. Limitaciones y honestidad metodológica

17.1. Sesgo de universo

El universo es ex post y depende de un proxy de liquidez-tamaño, no de FFMC ni de GICS point-in-time institucional. Por ello, el sesgo de supervivencia sigue presente.

17.2. Fuente de datos

La fuente operativa es `yfinance`. Es útil para investigación reproducible, pero no sustituye una infraestructura institucional de datos.

18. Conclusiones

Con base en los resultados obtenidos, se concluye que el proyecto cumple de forma satisfactoria con su objetivo, ya que logró construir una arquitectura cuantitativa sólida, modular y explicable, capaz de participar en el crecimiento del sector tecnológico sin depender de una lógica de predicción directa de precios. Mahoraga 6.1 mostró una mejora relevante frente a QQQ en términos de eficiencia y control del drawdown, mientras que Mahoraga 7C.3 añadió una capa de supervisión inteligente que fortaleció el comportamiento del sistema, especialmente en escenarios de mayor fragilidad o tensión del mercado. En conjunto, el proyecto demuestra que la integración disciplinada de estadística adaptativa, detección de régimen y aprendizaje automático puede traducirse en una estrategia más robusta, defendible y útil para la toma de decisiones cuantitativas.

Mahoraga representa una arquitectura cuantitativa bien pensada y progresivamente refinada. Su valor no está en prometer predicción perfecta, sino en construir una solución por capas:

1. Mahoraga 6.1 establece una base robusta, con validación walk-forward, universo canónico, señales compuestas y control adaptativo del riesgo.

2. Mahoraga 7 introduce memoria de régimen mediante intensidades Hawkes inspiradas, capturando mejor el agrupamiento de estrés y recuperación.

3. Mahoraga 7C.3 añade una supervisión dual con aprendizaje automático que mejora de forma incremental, particularmente en las zonas donde el baseline se vuelve más frágil.

Finalmente, podemos afirmar que el uso de IA da un valor agregado real sobre una base cuantitativa bien planteada, ayudando no como motor principal, sino como una forma de intervención y corrección sobre el modelo 6.1, ayudando de esta forma al cumplimiento del objetivo de este proyecto.