Mahoraga 14.1: consolidación auditada de un sistema long-only con alpha residualizado, overrides estructurales y continuation lift bajo validación walk-forward

Salazar Martínez Liam Antonio

29 de abril de 2026

Resumen

Mahoraga 14.1 es una consolidación auditada de Mahoraga 14 cuyo objetivo no es expandir la arquitectura del sistema, sino verificar que el modo FULL produzca salidas out-of-sample confiables, trazables y consistentes con el modo FAST. La implementación final conserva tres elementos operativos: un motor base de alpha (`BASE\_ALPHA\_V2`), una defensa estructural (`STRUCTURAL\_DEFENSE\_ONLY`) y un módulo de continuation lift (`CONTINUATION\_PRESSURE\_V2\_ONLY`), además de una rama combinada con ambos overrides. El trabajo documenta la arquitectura efectiva del código, distingue los módulos activos de los descartados, y formaliza la auditoría FULL sobre stitched out-of-sample, recomputación de *maximum drawdown*, suite de stress y Monte Carlo con dependencia temporal preservada.

En stitched OOS, `BASE\_ALPHA\_V2` obtiene 24.52% de CAGR, 1.1887 de Sharpe y -20.24% de MaxDD, mientras que `BASE\_ALPHA\_V2+CONTINUATION\_PRESSURE\_V2\_ONLY` alcanza 24.68%, 1.1937 y -20.24%, respectivamente. La mejora directa frente a la base es pequeña pero real en el stitched agregado ($p = 0.033412$), aunque no sobrevive la corrección por multiplicidad disponible en la corrida FULL ($q = 1.0$). Por separado, el alpha anualizado con covarianza Newey-West frente a `QQQ` y `SPY` permanece positivo y con estadísticos t superiores a 2 en la muestra stitched. La auditoría FULL confirma que el stitched concatena exclusivamente ventanas `TEST\_ONLY`, sin solapes ni huecos, y que el MaxDD reportado coincide exactamente con una recomputación independiente. La evidencia respalda a Mahoraga 14.1 como una versión metodológicamente consolidada y apta para análisis técnico, aunque con límites claros: mejoras incrementales, activaciones de continuation escasas y restricciones de universo derivadas del uso de *LiqSizeProxy* en lugar de FFMC/GICS de verdadera naturaleza point-in-time.

1 Introducción

Mahoraga es un sistema long-only sobre un universo concentrado de emisores tecnológicos y de plataforma cuyo objetivo operativo es producir una trayectoria out-of-sample superior a una base histórica interna (`LEGACY`), y competitiva frente a `QQQ` y `SPY`, sin abandonar trazabilidad del pipeline ni interpretabilidad de las decisiones. En Mahoraga 14.1, ese objetivo se redefine con una restricción adicional: antes de extraer conclusiones económicas, el modo FULL debe demostrar integridad metodológica en stitched OOS, drawdown, stress testing y Monte Carlo.

Esta exigencia no es retórica. El proyecto arrastraba dos riesgos históricos concretos: un stitched OOS mal armado que contaminaba la lectura out-of-sample, y episodios donde stitched o stress

inflaban artificialmente el MaxDD. Por ello, Mahoraga 14.1 debe leerse como una consolidación auditada antes que como una versión expansiva. La pregunta central es doble: qué sobrevive realmente en la implementación final, y cuál es la evidencia empírica que sigue siendo defendible una vez auditado el pipeline FULL.

2 Evolución del proyecto y antecedentes de investigación

La base histórica del proyecto permanece preservada en `mahoraga6\_1.py`, mientras que el paquete `mahoraga14/` modulariza la lógica en componentes separados de datos, motor de alpha, overrides, ejecución de backtest y reporte. La documentación interna explicita dos decisiones arquitectónicas relevantes: no existe capa Markov y la señal Hawkes se utiliza sólo como señal rápida de transición, no como un modelo puntual completamente estimado.

La consolidación 14.1 mantiene cinco hipótesis previas y descarta otras. Sobreviven: (i) `BASE\_ALPHA\_V2` como base fuerte; (ii) `CONTINUATION\_PRESSURE\_V2\_ONLY` como mejora stitched pequeña pero real; (iii) `STRUCTURAL\_DEFENSE\_ONLY` como módulo de apoyo al suelo, no como rama principal; (iv) alpha benchmark-adjusted positivo frente a `QQQ` y `SPY`; y (v) necesidad de auditoría completa antes de interpretar FULL. En cambio, quedan fuera de la descripción final del sistema los clasificadores standalone de transición/recuperación, la capa Markov, el *ML RegimeGate* histórico, cualquier rama long-short y cualquier módulo de deep learning o reinforcement learning. También se descarta el FULL como motor de descubrimiento combinatorio amplio: en 14.1 se convierte en un modo de auditoría dirigido, con la misma malla focalizada que FAST.

Desde el punto de vista metodológico, las piezas que sí tienen apoyo explícito en la implementación se apoyan en referencias conocidas pero usadas de forma acotada: covarianza HAC de Newey y West para alpha frente a benchmark, *hierarchical risk parity* para el reparto intracartera, regularización ridge en la residualización y clasificadores logísticos / *random forest* como retadores sencillos y auditables [5, 4, 3, 1]. La analogía Hawkes se conserva sólo a nivel de intensidades decaídas de eventos de estrés y recuperación [2].

3 Datos, universo y preparación de información

La configuración auditada cubre datos diarios entre 2005-01-01 y 2026-02-20, con capital inicial de 100,000 unidades monetarias y decisión semanal en cierres de viernes. El pipeline consume series OHLCV para el universo operativo y para los benchmarks `QQQ`, `SPY` y, cuando está disponible, `VIX`. En el cargado de datos también se recuperan factores FF, pero la capa FULL auditada de Mahoraga 14.1 no utiliza esa información en sus salidas operativas; por ello no se presenta aquí como componente activo del sistema final.

El universo auditado es un universo canónico reconstituido trimestralmente con una variable de ranking denominada *LiqSizeProxy*, definida como el promedio de precio por volumen sobre 30 días. El motor de universo usa tamaño objetivo 10, autoentrada hasta rank 8, retención hasta rank 10, buffer hasta rank 13, estacionalidad mínima de 63 días y volumen dólar promedio mínimo de USD 50 millones. La propia base histórica del proyecto explicita que este mecanismo no es FFMC ni clasificación GICS-IT real; para ello harían falta datos CRSP/Compustat point-in-time que no forman parte de la implementación auditada. En consecuencia, Mahoraga 14.1 reduce, pero no elimina plenamente, los riesgos de sesgo de supervivencia y de clasificación ex post.

La preparación de información opera en dos escalas. En frecuencia diaria se construyen scores, pesos, stops, escalados de riesgo, costos y benchmarks. En frecuencia semanal se genera un *dataset* de trayectoria y contexto de mercado que alimenta a la defensa estructural, a continuation y a la

señal Hawkes-style. Esta separación es importante: los overrides se calibran semanalmente, pero su efecto se traslada a ejecución diaria mediante un mapeo semanal-a-diario auditado.

4 Arquitectura del sistema

La arquitectura final de Mahoraga 14.1 puede describirse en cuatro capas. La primera es un motor base de alpha que produce pesos objetivo y una trayectoria base (`BASE\_ALPHA\_V2`). La segunda es una trayectoria defensiva precomputada con el mismo conjunto de componentes de alpha, pero con distinta mezcla de score y penalización de beta. La tercera es una capa superior de overrides semanales que decide, en cada fecha de decisión, si conviene activar defensa estructural o continuation lift. La cuarta es la capa de auditoría FULL, implementada en `full\_report.py`, que reconstruye stitched OOS, verifica integridad temporal, recompone equity y drawdown, ejecuta stress tests y produce Monte Carlo con dependencia temporal preservada.

La ruta de ejecución efectiva es estricta: `mahoraga14\_runner.py` crea la configuración; `mahoraga14\_data.py` carga datos y universo; `backtest\_executor.py` corre el walk-forward y ensambla las variantes; `full\_report.py` construye la salida FULL auditada. Esa ruta no llama a los clasificadores standalone de transición/recuperación, y por lo tanto dichos módulos no deben interpretarse como parte activa de Mahoraga 14.1, aunque sigan presentes en el repositorio como referencia histórica.

5 Metodología

La metodología de Mahoraga 14.1 combina calibración dirigida y auditoría posterior. El modo FAST y el modo FULL comparten la misma malla focalizada de hiperparámetros. Esta decisión es explícita en configuración: FULL deja de ser una búsqueda combinatoria abierta y se restringe a la misma cuadrícula de `base\_mix`, `defense\_mix`, penalizaciones de beta y `raw\_rel\_boost` usada por FAST. El objetivo es preservar comparabilidad entre ambos modos y evitar que FULL se convierta en una fuente adicional de sobreajuste o en un proceso computacional explosivo.

La comparación empírica se organiza alrededor de tres candidatos auditados: `BASE\_ALPHA\_V2`, `BASE\_ALPHA\_V2+CONTINUATION\_PRESSURE\_V2\_ONLY` y `BASE\_ALPHA\_V2+STRUCTURAL\_DEFENSE\_ONLY+CONTINUATION\_PRESSURE\_V2`. `STRUCTURAL\_DEFENSE\_ONLY` se conserva como referencia auxiliar. Los benchmarks obligatorios son `LEGACY`, `QQQ` y `SPY`. Las pruebas directas de comparación usan p-values emparejados sobre retornos de ventana y su ajuste BHY disponible en el pipeline. El alpha ajustado por benchmark se estima mediante una regresión

$$r_t^{(s)} = \alpha + \beta r_t^{(b)} + \varepsilon_t, \tag{1}$$

con covarianza HAC Newey-West y anualización del intercepto [5]. Esta distinción es central en la lectura de resultados: un alpha positivo frente a benchmark no es equivalente a una mejora estadísticamente sólida frente a la base interna después de corrección por multiplicidad.

6 Construcción del motor de alpha

El motor `BASE\_ALPHA\_V2` mezcla un *core* legado con una capa adaptiva residualizada. El *core* legado se compone de tres bloques: tendencia, momentum y momentum relativo contra `QQQ`. En paralelo, la capa adaptiva construye un score en precios brutos y otro en precios residualizados frente

a cuatro factores: `QQQ`, `SPY`, un factor `TECH` definido como retorno medio transversal del universo y el primer componente principal (`PC1`) de los retornos de entrenamiento.

La residualización se estima por activos mediante regresión ridge rodante con ventana de 63 observaciones, mínimo de 42 observaciones, $\alpha = 8.0$ y recorte de retornos residualizados a ± 0.25. Sobre la trayectoria residualizada se recomputan señales de tendencia y momentum. Los pesos del bloque bruto se aprenden con IC transversal y luego se contraen hacia un prior uniforme $(1/3, 1/3, 1/3)$ con `raw\_weight\_shrink`=0.70; los pesos del bloque residualizado se contraen hacia $(0.5, 0.5)$ con `resid\_weight\_shrink`=0.60. El score diario final sigue la forma

$$\text{legacy_core}_{i,t} = z\big(w_{tr}\,\text{legacy_tr}_{i,t} + w_{mo}\,\text{legacy_mo}_{i,t} + w_{re}\,\text{legacy_re}_{i,t}\big)\,, \tag{2}$$

$$\text{raw_score}_{i,t} = w_1^{raw}\,\text{raw_tr}_{i,t} + w_2^{raw}\,\text{raw_mo}_{i,t} + w_3^{raw}\,\text{raw_re}_{i,t}, \tag{3}$$

$$\text{resid_score}_{i,t} = w_1^{res}\,\text{resid_tr}_{i,t} + w_2^{res}\,\text{resid_mo}_{i,t}, \tag{4}$$

$$\text{adaptive_score}_{i,t} = 0.62\,\text{raw_score}_{i,t} + 0.38\,\text{resid_score}_{i,t} - \text{beta_drag}_{i,t}, \tag{5}$$

$$\text{score}_{i,t} = z\big((1-m)\,\text{legacy_core}_{i,t} + m\,\text{adaptive_score}_{i,t}\big)\,. \tag{6}$$

El término `beta\_drag` penaliza exposiciones con beta superior a 1.0. El score se anula durante el *burn-in* inicial, definido como el máximo entre 252 días y el *burn-in* residual de 126 días. En términos funcionales, el motor base persigue una combinación de persistencia direccional, momentum relativo y depuración parcial del movimiento de benchmark.

7 Construcción de cartera y ejecución

En cada fecha de rebalanceo semanal se seleccionan hasta tres nombres con score positivo. Si sólo hay un nombre elegible, se asigna peso unitario; si hay dos o más, se utiliza *hierarchical risk parity* (HRP) sobre una ventana de 252 días, con retroceso a historial completo si la ventana reciente es insuficiente, y con tope de peso individual de 60% [4]. Si no hay nombres elegibles, la cartera permanece en efectivo.

Los pesos objetivo pasan por un *Chandelier stop* antes de ejecutarse. Los pesos ejecutados quedan desplazados un día (`shift(1)`), con lo que la simulación evita ejecutar el mismo día en que se observa el score o se activa el stop. La serie de retornos brutos se obtiene como producto entre pesos ejecutados y retornos diarios del universo. La ejecución neta deduce costos proporcionales al turnover; en la configuración base auditada, la comisión es 10 bps y el slippage 3 bps.

La reconstrucción de equity responde a la expresión

$$E_t = E_0 \prod_{s \le t} (1 + r_s^{net}), \tag{7}$$

con $E_0 = 100{,}000$. Esta definición se usa de manera uniforme en backtest, stitched, stress suite y auditoría de MaxDD. El benchmark `QQQ` descuenta además un costo anual de gastos del ETF, mientras que `SPY` se usa sobre retorno simple diario.

8 Gestión de riesgo y reglas de salida

La gestión de riesgo se implementa por capas. Primero se estima una volatilidad realizada sobre 63 días y se compara con una volatilidad objetivo anual de 30%. Luego se impone un cap multiplicativo formado por `crisis\_scale`, `turb\_scale`, un veto secundario de correlación y, en caso de override, los multiplicadores `gate\_scale` y `exp\_cap`. Si la correlación media cruza 0.90, el veto secundario

escala la exposición a 0.80. La exposición final efectiva corresponde al mínimo entre escala por volatilidad y cap agregado, y también se desplaza un día antes de aplicarse.

Las reglas de salida forman parte de la propia construcción de pesos y del bloque de overrides. En la ruta base, los *stops* liberan la posición. En la ruta estructural, el sistema puede forzar una mezcla parcial hacia la trayectoria defensiva y reducir techo de exposición. En la ruta continuation, el sistema no reemplaza la cartera base; sólo relaja ligeramente los topes de escala cuando la señal de continuation supera umbrales de activación y mantiene bajo el riesgo de ruptura.

El drawdown se define de forma canónica como

$$DD_t = \frac{E_t}{\max_{s \le t} E_s} - 1. \tag{8}$$

Esta misma definición se reutiliza en la auditoría FULL para evitar discrepancias entre drawdown reportado y equity reconstruida.

9 Overrides y capa superior

La capa superior contiene dos módulos activos. El primero es la defensa estructural. A partir de un *dataset* semanal con información de drawdown, duración de drawdown, velocidad, rebote, eficiencia, share de pérdidas, densidad de stops, persistencia de correlación, amplitud transversal, drawdown de `QQQ`, `VIX` y escalas de crisis/turbulencia/correlación, se construye una etiqueta `structural\_y` asociada a retornos futuros bajos, empeoramiento del drawdown y debilidad relativa. El modelo estructural elige entre un clasificador logístico estandarizado y un *random forest* retador, quedándose con el que maximiza AUC de validación.

La probabilidad `structural\_p` no actúa sola. El score semanal de defensa se define como

$$\text{structural_score} = 0.74\,\text{structural_p} + 0.22\,\text{structural_path} + 0.04\,w_H\,\text{stress_hawkes}, \tag{9}$$

donde `structural\_path` resume la geometría reciente del drawdown y `stress\_hawkes` es la intensidad Hawkes-style de estrés. Si el score supera el umbral calibrado y se cumplen guardas adicionales de deterioro de trayectoria, la capa superior activa `STRUCTURAL\_DEFENSE`: mezcla parcialmente la trayectoria base con una trayectoria defensiva precomputada y reduce `gate\_scale`, `vol\_mult` y `exp\_cap`.

El segundo módulo activo es `CONTINUATION\_PRESSURE\_V2`. Su diseño está separado en tres subproblemas: *trigger*, *pressure* y *break-risk*. Las características de *trigger* enfatizan liberación de stops, rebotes de amplitud y estados de compresión; las de *pressure* miden eficiencia de trayectoria, amplitud de swings, retornos recientes y relación frente a `QQQ`; las de *break-risk* combinan esos elementos con riesgo de estrés Hawkes-style. Cada submodelo elige entre logística y *random forest* según AUC de validación. Los scores principales son

$$\text{trigger_score} = 0.65\,\text{trigger_p} + 0.35\,\text{trigger_context}, \tag{10}$$

$$\text{pressure_score} = 0.60\,\text{pressure_p} + 0.40\,\text{pressure_context}. \tag{11}$$

La activación de continuation exige que la defensa estructural no esté activa, que exista compresión o pausa válida, apoyo de benchmark, alguna señal gatillo de liberación o rebote, score estructural suficientemente bajo y probabilidad de *break-risk* por debajo de un cap calibrado. Si se cumple esa combinación, el sistema activa `CONTINUATION\_LIFT`. Es importante subrayar que continuation no construye una cartera nueva: mantiene `defense\_blend`=0 y sólo relaja moderadamente `gate\_scale`, `vol\_mult` y `exp\_cap` en proporción a una intensidad suave de continuation. En este sentido, continuation es una capa de exposición, no un motor de alpha alternativo.

El rol de Hawkes en esta sección debe interpretarse de forma literal. La implementación final no estima un proceso Hawkes multivariante. En cambio, define eventos de estrés y recuperación y propaga intensidades por la recurrencia

$$\lambda_t = \delta\lambda_{t-1} + I_{t-1}, \tag{12}$$

con $\delta = 0.70$ y recorte posterior de la intensidad. Por ello, el término correcto para el paper es *señal Hawkes-style* o *Hawkes-inspired*, no *modelo Hawkes estimado*.

10 Backtesting y protocolo walk-forward

El backtest se organiza en cinco folds expandentes con embargo explícito de 252 días entre fin de entrenamiento y comienzo de validación. Las ventanas son: (i) entrenamiento hasta 2013-12-31, validación 2015-01-02 a 2016-12-30 y test 2017-01-03 a 2018-12-31; (ii) entrenamiento hasta 2015-12-31, validación 2017-01-03 a 2018-12-31 y test 2019-01-02 a 2020-12-31; (iii) entrenamiento hasta 2017-12-29, validación 2019-01-02 a 2020-12-31 y test 2021-01-04 a 2022-12-30; (iv) entrenamiento hasta 2019-12-31, validación 2021-01-04 a 2022-12-30 y test 2023-01-03 a 2024-06-28; y (v) entrenamiento hasta 2021-12-31, validación 2023-01-03 a 2024-06-28 y test 2024-07-01 a 2026-02-20.

La selección de hiperparámetros durante calibración sigue una lógica heredada de Mahoraga 14: la malla principal se organiza alrededor de `STRUCTURAL\_DEFENSE\_ONLY` como `main\_variant\_key`. Sin embargo, la capa FULL auditada en 14.1 fija `CONTINUATION\_PRESSURE\_V2\_ONLY` como `full\_primary\_variant\_key`. Este detalle no es un bug, sino una decisión de consolidación: la calibración conserva comparabilidad con FAST, mientras que la auditoría final se centra en la rama continuation, que es la mejora stitched más defendible sobre la base.

11 Auditoría FULL: stitched, MaxDD, stress tests y Monte Carlo

Stitched OOS

La auditoría stitched produce una traza por fold (`stitched\_full\_trace.csv`) y un conjunto de chequeos de integridad (`stitched\_integrity\_checks.csv`). Para todas las variantes y benchmarks auditados, la concatenación utiliza exclusivamente ventanas `TEST\_ONLY` con filas por segmento [502, 505, 503, 374, 411], sin solapes y sin huecos. Los índices stitched son monótonos, únicos y coinciden con el calendario OOS efectivo esperado. La reconstrucción de exposición, turnover y costos también pasa verificación.

El único chequeo informativo que no es estrictamente verdadero en sentido nominal es `requested\_bounds\_fully\_available`: el fold 5 se pide hasta 2026-02-20, pero el calendario efectivo realizable termina en 2026-02-19. La traza expone esta diferencia de forma explícita y la clasificación final permanece en PASS porque la concatenación coincide con el calendario OOS efectivamente disponible. Esta es una diferencia importante frente a errores históricos: el límite efectivo se declara, no se oculta.

Auditoría de MaxDD

La auditoría de drawdown reconstruye la equity stitched desde retornos netos diarios, calcula el *running peak* y recompone el drawdown con la misma definición usada en el backtest. Los resultados se guardan en `maxdd\_audit\_full.csv` y `maxdd\_audit\_notes.md`. En todas las variantes y benchmarks, el MaxDD almacenado coincide exactamente con el MaxDD reconstruido; la diferencia

auditada es 0.0 puntos base. Para la base y el candidato continuation, el episodio máximo stitched se localiza entre el pico del 2020-09-01 y el trough del 2020-11-10, con recuperación el 2021-07-23. Por lo tanto, el MaxDD reportado en FULL no proviene de una recomposición defectuosa del stitched.

Stress suite

La suite de stress auditada incluye aumentos de costos (+25%, +50%, +100%), slippage adicional, delay de un rebalance, falsos positivos extra en continuation, falsos positivos extra en structural defense, reducción del continuation lift, stress conjunto de `gate\_scale/vol\_mult/exp\_cap` y un *empirical tail block path stress*. Según `stress\_suite\_audit.md`, todos los escenarios no basados en trayectoria recomputan retornos, equity, drawdown y alpha desde las mismas ventanas stitched `TEST\_ONLY`; los benchmarks mantienen sus trayectorias base para comparación.

El *empirical tail block path stress* reemplaza bloques de retornos por episodios empíricos de cola ya observados, preservando estructura temporal a nivel de bloque. Esta decisión es metodológicamente más consistente con el objetivo de auditoría que una perturbación IID. Sin embargo, la suite debe interpretarse como análisis de sensibilidad, no como garantía de que todo stress empeora todas las métricas. De hecho, algunos escenarios de falsos positivos estructurales mejoran marginalmente la muestra del combo y de la rama estructural, lo cual se documenta de forma explícita en los resultados y no se fuerza a interpretación adversa.

Monte Carlo y bootstrap

Mahoraga 14.1 incorpora tres herramientas de robustez. La primera es un *stationary block bootstrap* sobre retornos stitched `TEST\_ONLY`, que preserva dependencia temporal local. La segunda es un Monte Carlo de fricciones que multiplica la serie de costos realizada. La tercera es una perturbación local de parámetros alrededor del candidato final continuation. No se incluye Monte Carlo IID ingenuo, precisamente para evitar destruir la estructura temporal del proceso.

Las salidas relevantes son `montecarlo\_summary\_full.csv`, `montecarlo\_percentiles\_full.csv` y `montecarlo\_audit.md`. El bootstrap estacionario es la pieza más informativa: para el candidato primario arroja mediana de CAGR de 24.27%, mediana de Sharpe de 1.1959 y mediana de MaxDD de -24.36%, con probabilidad de 28.5% de caer por debajo de Sharpe 1 y de 44.75% de registrar un MaxDD inferior a -25%. La simulación de fricciones y la vecindad local muestran dispersión mucho menor, como es esperable dado que exploran perturbaciones más acotadas.

12 Resultados

La Tabla 1 resume el stitched OOS final. La base fuerte del sistema es `BASE\_ALPHA\_V2`, con 24.52% de CAGR, 1.1887 de Sharpe y -20.24% de MaxDD. Frente a esta base, la rama continuation produce 24.68%, 1.1937 y -20.24%, mientras que la rama combinada produce 24.57%, 1.1912 y -20.27%. La rama puramente estructural queda en 24.41%, 1.1862 y -20.27%. Frente a benchmarks, el candidato continuation supera a `LEGACY`, `QQQ` y `SPY` tanto en CAGR como en Sharpe y MaxDD stitched.

Table 1: Comparacion stitched OOS FULL de los candidatos auditados y benchmarks obligatorios. El alpha Newey-West se reporta en terminos anualizados frente a `QQQ` y `SPY`.

Variante	CAGR (%)	Sharpe	MaxDD (%)	Exposicion media	Turnover medio	AlphaNW QQQ	AlphaNW SPY
LEGACY	23.07	1.1348	-21.11	0.6069	0.0331	0.1400	0.1729
QQQ	20.14	0.9178	-35.24	1.0000	0.0000	0.0000	0.0294
SPY	14.88	0.8463	-33.72	1.0000	0.0000	-0.0021	0.0000
BASE_ALPHA_V2	24.52	1.1887	-20.24	0.6303	0.0345	0.1479	0.1814
BASE + CONTINUATION_PRESSURE_V2_ONLY	24.68	1.1937	-20.24	0.6316	0.0345	0.1494	0.1830
BASE + STRUCTURAL_DEFENSE_ONLY + CONTINUATION_PRESSURE_V2	24.57	1.1912	-20.27	0.6269	0.0342	0.1498	0.1832
BASE + STRUCTURAL_DEFENSE_ONLY	24.41	1.1862	-20.27	0.6256	0.0342	0.1484	0.1817

La lectura estadística requiere separar dos niveles. Primero, la mejora directa continuation vs. base tiene un p-value stitched de 0.033412, coherente con una mejora pequeña pero real. Segundo, el ajuste BHY disponible en la corrida devuelve $q = 1.0$, de modo que esa evidencia no debe presentarse como una ganancia robusta bajo control estricto de multiplicidad. En paralelo, el alpha anualizado Newey-West stitched del candidato continuation es 0.1494 frente a `QQQ` ($t = 2.490$) y 0.1830 frente a `SPY` ($t = 2.716$). Así, el benchmark-adjusted alpha sigue siendo positivo y estadísticamente más convincente que la comparación directa corregida frente a la base.

La Tabla 2 resume la jerarquía de ramas. `STRUCTURAL\_DEFENSE\_ONLY` mejora modestamente el suelo promedio (0.5392 vs. 0.5291 de Sharpe en folds de piso), pero no supera a la base en stitched total y queda clasificada como `MAIN\_BRANCH\_FAIL`. `CONTINUATION\_PRESSURE\_V2\_ONLY` mejora techo, suelo y stitched, pero carga la nota `fold3\_below\_main`; aun así, en 14.1 se adopta como candidato primario porque su mejora stitched es la más nítida y consistente con el objetivo de auditoría. La rama combinada pasa filtros, pero sin un perfil suficientemente superior como para desplazar a continuation.

Table 2: Resumen de piso/techo y estatus de seleccion de las ramas auditadas. La defensa estructural mejora modestamente los folds de suelo, pero no supera a la base en stitched agregado.

Variante	Ceiling Sharpe	Delta ceiling	Floor Sharpe	Delta floor	Stitched Sharpe	Delta stitched	Estatus
BASE_ALPHA_V2	1.5523	0.0000	0.5291	0.0000	1.1887	0.0000	OFFICIAL_BASELINE
BASE + STRUCTURAL_DEFENSE_ONLY	1.5378	-0.0146	0.5392	0.0101	1.1862	-0.0025	MAIN_BRANCH_FAIL
BASE + CONTINUATION_PRESSURE_V2_ONLY	1.5589	0.0066	0.5310	0.0019	1.1937	0.0050	REJECT
BASE + STRUCTURAL_DEFENSE_ONLY + CONTINUATION_PRESSURE_V2	1.5444	-0.0080	0.5411	0.0120	1.1912	0.0025	PASS_NOT_PROMISING

La utilización efectiva de los overrides también es informativa. En stitched, continuation registra una tasa de lift de 5.19% y una tasa de activación de 2.10%, lo que confirma que se trata de una intervención escasa y selectiva. El event study stitched sobre 10 activaciones muestra retornos medios posteriores de 0.69% a 1 semana, 3.28% a 2 semanas y 6.26% a 4 semanas, frente a 1.88% a 4 semanas en no activaciones. Esta evidencia es descriptiva y consistente con la hipótesis del módulo, pero su tamaño muestral obliga a prudencia interpretativa.

Table 3: Event study stitched de activaciones de continuation para el candidato primario. La muestra es pequena y debe interpretarse como evidencia descriptiva auxiliar.

Variante	Activaciones	Hit rate	Retorno medio 1W	Retorno medio 2W	Retorno medio 4W	Drawdown medio 4W
Activacion continuation	10	0.5833	0.0069	0.0328	0.0626	-0.0066
No activacion	466	0.5258	0.0043	0.0090	0.0188	-0.0260

En calibración, los submodelos de continuation muestran AUCs razonables pero heterogéneos por fold. El AUC del *trigger* oscila aproximadamente entre 0.67 y 0.87; el de *pressure*, entre 0.58 y 0.79; y el de *break-risk*, entre 0.76 y 0.80. Estos valores respaldan que continuation no es una regla puramente ad hoc, pero también confirman que la señal no es uniformemente fuerte en todos los regímenes.

La auditoría de stitched y MaxDD se resume en la Tabla 4. La igualdad entre MaxDD almacenado y recomputado descarta el tipo de contaminación que motivó Mahoraga 14.1. En otras palabras, la mejora continuation no descansa en una construcción defectuosa de equity o drawdown.

Table 4: Resumen de auditoria FULL para stitched y MaxDD. Todas las variantes pasan integridad de stitched, reconstruccion de equity y recomputacion independiente de drawdown.

Chequeo	Resultado	Detalle principal	Implicacion
Ventanas stitched	PASS	solo segmentos TEST_ONLY	no hay contaminacion de train/val
Traza por fold	PASS	filas [502, 505, 503, 374, 411]	sin perdidas de observaciones
Overlap / gaps	PASS	overlap=False; gap=0 por fold	concatenacion contigua
Indices temporales	PASS	monotonicidad e indices unicos	calendario stitched valido
Equity reconstruible	PASS	max_abs_diff = 0	equity final consistente
Drawdown reconstruible	PASS	drawdown desde equity stitched	sin recomposicion por piezas
MaxDD audit	PASS	diff = 0.0 bps	MaxDD no artefactual
Disponibilidad nominal fold 5	INFO	pedido 2026-02-20; efectivo 2026-02-19	diferencia explicita, no error de stitched

La sensibilidad del candidato primario se muestra en la Tabla 5. El mayor deterioro de Sharpe proviene del *empirical tail block path stress* (1.0255) y del doblado de costos (1.1378), mientras que el peor MaxDD aparece bajo delay de ejecución (-20.56%) o continuation false positives extra (-20.68%). El stress de `gate/vol/cap` reduce CAGR, pero mejora el MaxDD hacia -18.59%, recordando que no todos los stresses representan daños unidireccionales: algunos miden el costo de ser más conservador.

Table 5: Stress suite del candidato primario `BASE_ALPHA_V2 + CONTINUATION_PRESSURE_V2_ONLY`. Los escenarios recalculan retornos, equity, drawdown y alpha sobre la misma serie stitched `TEST_ONLY`.

Escenario	CAGR (%)	Sharpe	MaxDD (%)	AlphaNW QQQ	AlphaNW SPY
Baseline	24.68	1.1937	-20.24	0.1494	0.1830
Costos +25%	24.33	1.1798	-20.27	0.1461	0.1796
Costos +50%	23.98	1.1658	-20.30	0.1429	0.1763
Costos +100%	23.28	1.1378	-20.37	0.1365	0.1697
Slippage +5 bps	24.14	1.1722	-20.29	0.1444	0.1778
Delay 1 rebalance	24.34	1.1435	-20.56	0.1356	0.1684
False positives continuation	24.67	1.1898	-20.68	0.1490	0.1828
Continuation lift -50%	24.61	1.1913	-20.24	0.1487	0.1823
Stress gate/vol/cap	21.54	1.2000	-18.59	0.1301	0.1587
Empirical tail block path stress	20.96	1.0255	-20.24	0.1167	0.1492

La robustez por simulación aparece en la Tabla 6. El stationary bootstrap mantiene una mediana cercana al stitched observado, pero revela dispersión significativa en drawdown: el percentil 5 del MaxDD para continuation cae a -36.88%. Esta cola no invalida la muestra base, pero obliga a reconocer que una trayectoria stitched favorable no elimina riesgo de deterioro severo bajo remuestreo por bloques.

Table 6: Monte Carlo y bootstrap del candidato primario. El bloque estacionario preserva dependencia temporal; la simulacion de fricciones y la perturbacion local se restringen a la implementacion final auditada.

Metodo	Muestras	Media CAGR (%)	Media Sharpe	Media MaxDD (%)	Pr(Sharpe < 1)	Pr(MaxDD $< -25\%$)
Stationary block bootstrap	400	24.84	1.1909	-25.36	0.2850	0.4475
Friction multiplier MC	300	24.68	1.1935	-20.24	0.0000	0.0000
Local parameter neighborhood	18	24.66	1.1929	-20.24	0.0000	0.0000

Las figuras auditadas complementan estas tablas. La Figura 1 muestra la trayectoria stitched comparada con `LEGACY`, `QQQ` y `SPY`. La Figura 2 permite verificar que la mejora frente a benchmarks no proviene de esconder drawdowns. La Figura 3 resume heterogeneidad por fold, la Figura 4 presenta el event study de continuation y la Figura 5 la distribución Monte Carlo.

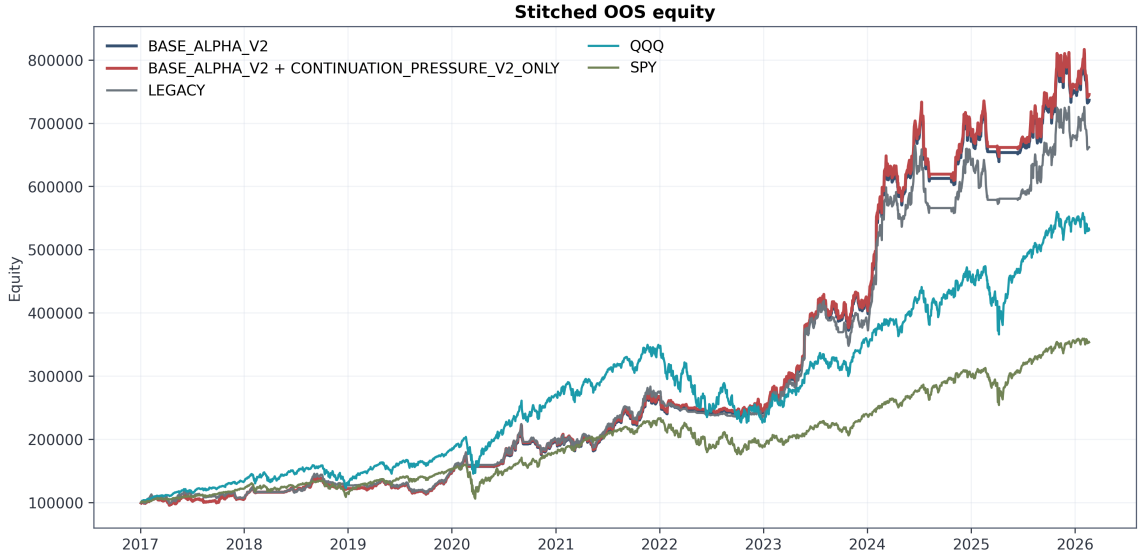

Figure 1: Trayectorias de equity stitched para la base, el candidato primario continuation y los benchmarks obligatorios. Archivo fuente: `equity\_curve\_stitched\_full.png`.

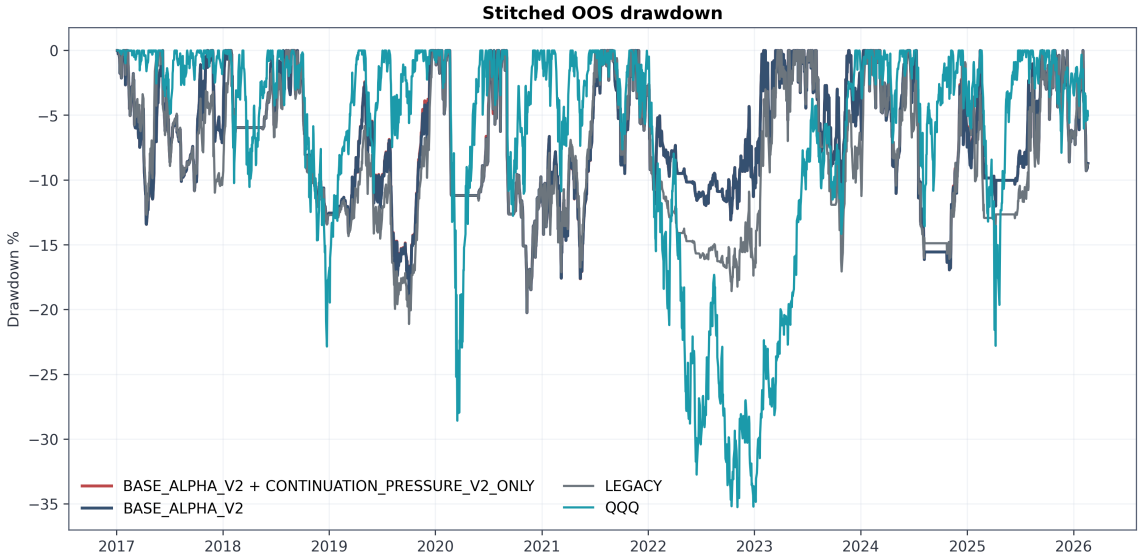

Figure 2: Curvas stitched de drawdown para el candidato primario, la base, `LEGACY` y `QQQ`. Archivo fuente: `drawdown\_curve\_stitched\_full.png`.

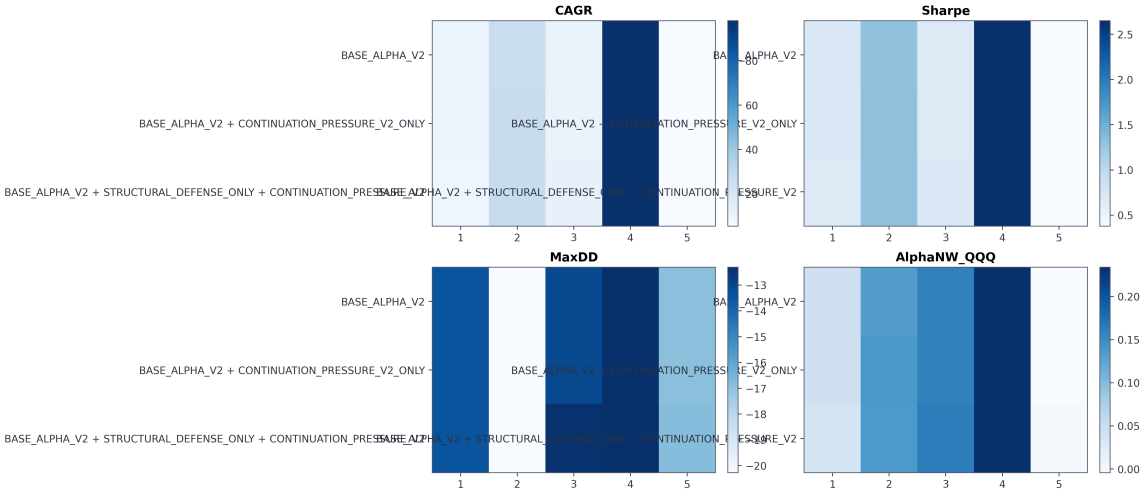

Figure 3: Mapa por fold de CAGR, Sharpe, MaxDD y alpha Newey-West para los candidatos auditados. Archivo fuente: `fold\_heatmap\_full.png`.

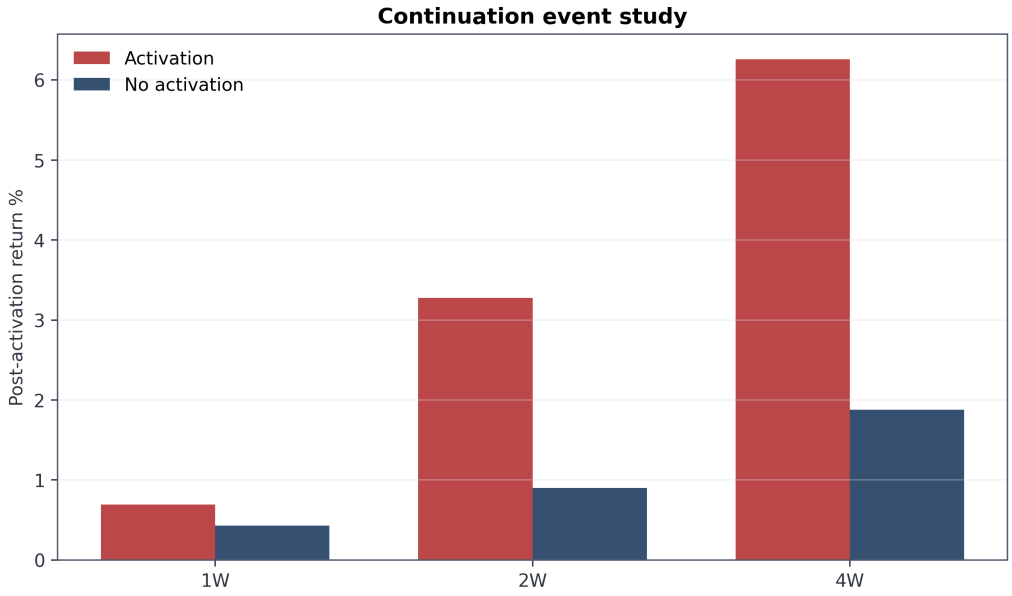

Figure 4: Retornos posteriores a activaciones de continuation frente a semanas sin activación. Archivo fuente: `continuation\_event\_study\_full.png`.

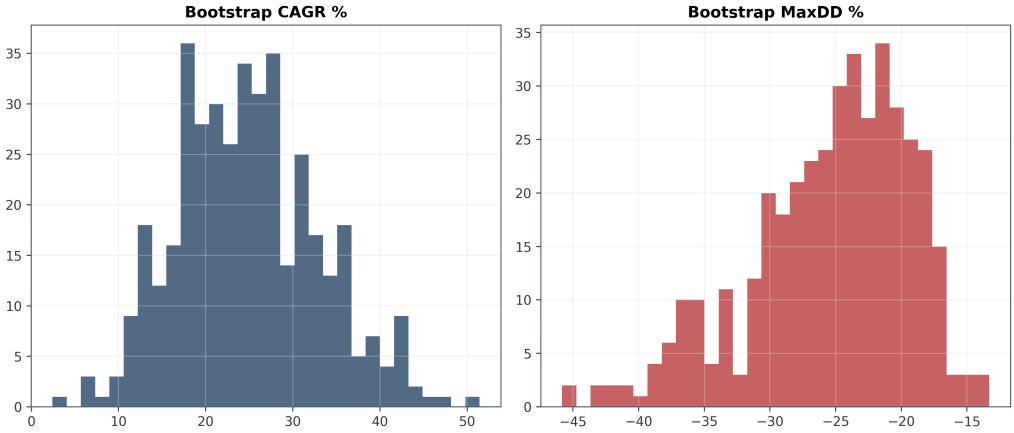

Figure 5: Distribuciones Monte Carlo y bootstrap para CAGR y/o MaxDD en las variantes auditadas. Archivo fuente: `montecarlo\_distribution\_full.png`.

13 Limitaciones

La primera limitación es de universo y datos. Aunque el motor canónico es point-in-time respecto al calendario local disponible, el ranking por *LiqSizeProxy* no equivale a FFMC ni a una clasificación GICS-IT. Por ello, la representación del universo tecnológico sigue siendo una aproximación operativa, no un universo institucional plenamente reproducible con datos CRSP/Compustat.

La segunda limitación es estadística. La mejora continuation sobre la base existe en stitched agregado, pero es pequeña y no sobrevive la corrección BHY disponible. En el mismo sentido, el event study stitched de continuation se apoya sólo en 10 activaciones, por lo que su lectura debe ser auxiliar y no concluyente.

La tercera limitación es de robustez. El stationary bootstrap muestra que la distribución de MaxDD es más adversa que la trayectoria stitched observada. Además, la suite de stress es razonable y trazable, pero no exhaustiva; en particular, el *empirical tail block path stress* representa una selección concreta de bloques adversos y no agota todos los regímenes plausibles.

La cuarta limitación es de alcance del paper. Este trabajo describe exclusivamente la implementación operativa de Mahoraga 14.1 y sus salidas FULL auditadas. No debe leerse como validación de módulos presentes en el repositorio pero inactivos en la ruta de ejecución final.

14 Conclusiones

Mahoraga 14.1 puede caracterizarse con precisión como una consolidación auditada de Mahoraga 14. El aporte principal no es una nueva arquitectura, sino la depuración metodológica del modo FULL. La auditoría confirma que el stitched OOS concatena exclusivamente ventanas `TEST\_ONLY`, que el MaxDD stitched coincide exactamente con una recomputación independiente y que la suite de stress y Monte Carlo opera sobre la serie correcta sin romper la dependencia temporal de forma ingenua.

En términos de desempeño, `BASE\_ALPHA\_V2` sigue siendo la base fuerte. La rama continuation aporta una mejora stitched pequeña pero real y se convierte en el candidato primario auditado de 14.1. La defensa estructural conserva valor como módulo de apoyo al suelo y como componente del combo, pero no como rama principal agregada. El alpha benchmark-adjusted frente a `QQQ` y `SPY` permanece positivo, mientras que la comparación directa continuation vs. base exige moderación por su fragilidad bajo corrección por multiplicidad.

En conjunto, la evidencia disponible respalda que Mahoraga 14.1 ya no debe evaluarse como un prototipo ambiguo de investigación, sino como una implementación auditable y coherente con FAST. Esa conclusión es suficientemente fuerte para documentación técnica y análisis formal, pero no autoriza exagerar la magnitud del edge ni ocultar los riesgos abiertos de universo, tamaño muestral y sensibilidad de cola.

References

References

[1] Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32.

[2] Hawkes, A. G. (1971). Spectra of some self-exciting and mutually exciting point processes. *Biometrika, 58*(1), 83–90.

[3] Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics, 12*(1), 55–67.

[4] López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *The Journal of Portfolio Management, 42*(4), 59–69.

[5] Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica, 55*(3), 703–708.